NBA Chat 方案说明

> NBA 场边智能问答 Demo · 笔试题交付 在线体验：NBA Chat(即开即用,无需配置;大陆网络访问 vercel.app 需自备代理)
> 文档更新日期：2026-10-12（北京时间）。对应最近已验证的上线代码 `48ce366` 。本文区分当前实现、交付验证与旧版评测记录；历史模型评测与成本样本见 `scripts/eval-results.md` ，不代表新版已通过全部 31 题复测。

---

1. 总体思路

以「每一场比赛，都值得看懂」为产品主张，做一个从赛程进入、围绕具体比赛持续追问的中文 Agent Demo。使用 NBA 视觉元素进行概念设计，不代表 NBA 官方发布的产品。

目标	手段	验证
事实可追溯	结构化卡片来自工具结果；纯单场球员统计正文由校验后的查询数据生成；开放式分析保留模型输出	当前真实模型统计联调通过，旧版 31 题评测单独保留；不承诺所有回答完全准确
体验连贯	今日赛程入口、流式输出、比分上下文、统计卡片与逐回合追问；本机历史会话	当前桌面与手机交互验证通过；本次线上单场统计样本约 5 秒，非性能分位数
合规稳健	六类红线话题按提示与查询策略引导回赛场	旧版 I1–I7 及记录中的变体通过；新版未重跑完整红线评测
即开即用	站方默认阿里云百炼服务，保留站方自选模型与 BYOK 设置	当前默认档生产联调通过；三档 7 例冒烟属于旧版验证

一个贯穿全程的判断:**评分权重里事实准确性 20% + 安全合规一票否决,而幻觉恰恰是 LLM 问答的默认失败模式**。所以方案的重心不在花哨功能,而在「用工具纪律 + 评测回路把事实错误压到最低」,并把每一步的实测结果(包括失败的)如实写进本文。

1.1 当前产品体验

- 首页采用深海军蓝、NBA 红与球场背景，主标题为「每一场比赛，都值得看懂」。背景与篮球缩略图为依据设计稿重建的 AI 氛围图，不代表某场真实赛事；球队标识来自 NBA 官方球队页公开 CDN。
- 默认展示北京时间「今天」，支持「昨天」和固定日期 2025-06-23 的「经典比赛」。推荐卡优先选择进行中的比赛，其次是未开赛的比赛，最后选择当天较晚的完赛记录。其余全部比赛放在「更多对阵」横向列表；当天只有一场时不显示该区域。
- 未开赛显示赛前看点与球队近况；进行中显示实时战况与球员数据；完赛显示复盘与最后两分钟；延期或取消显示赛程状态，不以 0:0 冒充当前比分。
- 聊天保留顶部比赛上下文，支持上半场、第三节、末节和最后两分钟记录查询。时间线可展开、收起，并基于具体日期、球队和回合继续追问；这些入口不是预填的分析结论。
- 手机端更多菜单包含新建会话、历史对话和设置。支持停止生成、复制回答、会话切换、日期标签键盘操作和弹层关闭后的焦点恢复。

2. 架构

```
浏览器（Next.js / React）
  ├─ 今日 / 昨日 / 经典比赛 → GET /api/games
  ├─ useChat / 比分上下文 / 统计卡 / 回合时间线
  ├─ 历史会话与模型设置 → localStorage
  └─ 当前会话消息 → POST /api/chat
                              │
Vercel Serverless             ▼
  ├─ 北京时间与赛季上下文 / 模型解析 / 查询策略
  ├─ 百炼模型 + AI SDK 多步工具循环（最多 16 步）
  ├─ 10 个工具 → ESPN / 中文维基 → 数据压缩
  ├─ 单场统计与复盘的证据补查
  ├─ 纯单场球员统计 → 校验数据后生成表格
  └─ 其他回答 → 模型流式正文 / 实例内存限流
```

- **未接会话数据库**：比赛数据来自外部公开服务；历史会话存在本机浏览器。对话生成仍会向服务器与模型服务发送当前会话上下文，不能将本地持久化理解为数据始终不离开设备。
- **服务端取数**:ESPN 调用全部在 Vercel 服务端完成,避免浏览器直连的 CORS 限制；外部数据源仍可能超时、限流或不可用。
- **单问生命周期**:用户输入 → 注入动态系统提示 → qwen-plus 决策 → 工具调用(ESPN → 压缩)→ 多步循环(≤16)→ 纯单场统计校验结果并生成表格，其他问题保留模型正文 → 流式响应回浏览器 → 渲染卡片/状态条 → 显示耗时。
- **技术栈**:Next.js 16(App Router)+ React 19 + TypeScript + Tailwind CSS 4;Vercel AI SDK(`ai` v7 + `@ai-sdk/openai-compatible`)接阿里云百炼 compatible-mode;react-markdown + remark-gfm 流式渲染;use-stick-to-bottom 吸底;vitest 单测 77 项。

2.1 会话与设置保存

项目	当前规则
历史位置	本机浏览器 localStorage，键为 `nba-chat-sessions`；不做云端会话同步
内容与容量	保存标题、消息、工具结果和更新时间；最多 50 个会话，超过后淘汰最久未更新的会话
保存时机	消息变化后约 500ms 自动保存；切换或新建会话时同步保存旧会话，生成中先停止再切换
保存期限	应用未设置 TTL；通常跨刷新与浏览器重启保留，直到手动删除、清除网站数据、数量淘汰或浏览器清理
隔离与边界	不同设备、浏览器及域名独立；无痕会话结束后通常清除。未实现存储配额不足时的恢复提示，不能保证永久保存
模型设置	客户端配置存于 `nba-chat-config`；BYOK 密钥也在本机 localStorage，不属于加密保险库。站方密钥只配置在服务端环境变量
请求范围	回答生成时，当前会话上下文发送至后端并由所选模型处理；不上传本机全部历史会话列表。模型服务的保留政策取决于提供商配置

3. 数据方案与实测记录

数据源只有两个:**ESPN 公开 JSON 端点**(赛程/赛果/单场/逐回合/排名/球员/新闻,无需鉴权)+ **中文维基百科**(历史背景、历年冠军列表)。不依赖任何内部库或付费数据。

工具层 10 个:`get_games_by_date`、`get_game_box`、`get_game_plays`、`get_series_or_games_lookup`(≤35 天区间)、`get_standings`、`search_player`、`get_player_stats`、`get_player_gamelog`、`get_champions`、`get_news_or_wiki`。

以下结论来自项目已记录的端点实测。ESPN 公开 JSON 接口不是本项目拥有的稳定服务契约，字段与可用性变化仍需监测：

端点/字段	实测结论(踩坑记录)
scoreboard `dates` 参数	按**美东日历日**组织。北京某日需查美东 D−1、D 两天,再按事件 UTC 时间戳回滤北京窗口(北京时间上午的比赛属于美东前一天)
scoreboard `series`	系列赛大比分**自带**(`series.summary` 如 "OKC Leads 3–2"),不必逐场累加
scoreboard `season`	`type` 1/2/3 = 季前/常规/季后赛,据此生成「2026–27 季前赛」标签，修复已复现的赛事阶段误标
summary(box)	两队球员名单对齐;压缩为每队按出场时间前 9 人、列裁剪 MIN/PTS/REB/AST/FG/3PT/FT/±
summary(plays)	支持最后 N 秒(仅第四节及加时)/仅得分回合/按节过滤;压缩后逐回合表与 ESPN 官网逐条一致
search `uid`	球员数字 id **藏在 uid 字符串里**(`s:40~l:46~a:4278073` → 4278073),需解析而非现成字段
gamelog	`seasonTypes` 分组结构(Regular Season / Postseason,后者含总决赛场次);`season` 参数是**结束年**(2024–25 赛季→2025)——早期文档误标为起始年,曾直接导致赛季标注错误(A3/A2/D1)
stats	该端点**忽略 season 参数,恒为生涯聚合**(seasontype 2/3 区分常规/季后)。评测中模型曾把生涯场均 25.3 误当赛季值(真实赛季值 31.9),修复方式:工具返回值显式标注「career 为生涯聚合」,并强制单季场均以 gamelog 分组汇总为准
中文维基冠军列表	简体页是重定向,须抓繁体页 wikitext;繁体队名(奥克拉荷馬雷霆/俄克拉何马城雷霆、印第安那溜馬等)需归一映射;解析出近 30 年年份→冠军/总决赛比分/亚军,压缩至 ~3.2KB

压缩层是成本与质量的关键:ESPN 原始响应单场可达 500KB+(逐回合全量),直接进上下文既慢又贵。压缩后工具结果 1–8KB,且在 gamelog 侧预先按组算好场均,避免模型心算出错。

4. 时间与赛季

问题	方案
「今天/昨天」按谁的日历算	三级换算:北京日历日 → 美东日期区间(北京一日恒覆盖美东 D−1 与 D 两天,夏冬令时均成立)→ 按事件 UTC 时间戳回滤北京窗口。评测 J2「昨天比赛」7 场比分/开球时间全对
赛季怎么算	动态注入:10 月起属新赛季(注意 10 月上中旬可能是季前赛,以工具返回标签为准)、4–6 月季后赛、7–9 月休赛期「本赛季」指刚结束赛季
season 传参口径	统一为赛季结束年(2024–25→2025),写死在提示词与全部工具描述里(实测曾错标,已修)
无年份指代	「G7/总决赛/上赛季」默认锚定最近发生该事件的赛季,先查证命中再作答,开头注明所指场次
未完场比赛	必须标注「比赛进行中」+ 当前节次比分,禁止终场口吻;追问时先说明数据实时变化再给最新比分(评测 K4 通过)

4.1 首页的数据更新机制

首页不是构建时写死的赛程。每次进入首页或切换日期，浏览器会按所选北京时间日期请求 `/api/games?date=YYYY-MM-DD`；服务端查询 ESPN，按实际开球 UTC 时间过滤当天窗口。

场景	当前行为
明天重新打开	默认日期重新按北京时间计算，查询明天当天赛程，无需重新部署
页面停留跨零点	日期订阅每 60 秒检查一次；页面重新可见也检查，所选「今天 / 昨天」随新日期更新
有进行中比赛	页面可见时每 30 秒重新请求所选日期的赛程；「更新」时间表示服务端本次取数时间，不是源数据的发布时刻
全部未开赛或已结束	不持续轮询。未开赛页面一直停留到开赛，需手动更新、切换日期或重新打开，才能发现新的直播状态
缓存与实时性	接口 `max-age=30, stale-while-revalidate=30`；访问上游使用 `no-store`。受短时缓存及 ESPN 更新速度影响，不承诺秒级同步或数据源 SLA
失败与空数据	失败提示重新查询，真实空数据提示该日期暂无比赛；不以占位比分或伪造比赛补齐页面

北京时间 2026-10-10 20:03 左右的线上核对：10 月 9 日接口返回 7 场，10 月 10 日返回 1 场（灰熊 104:100 公牛），10 月 11 日返回 8 场预定赛事；同时核对覆盖日期的 ESPN 原始赛程。该数量是一次查询快照，不作为以后日期的固定数据。

5. 可靠性与合规

5.1 查询纪律与统计校验

以下是系统提示中的约束目标，不等同于模型每次都能遵守：

- 客观数字必须来自工具结果;**记忆与工具冲突一律以工具为准**(模型的篮球先验可能过时甚至属于另一个数据世界);

- 用户前提先查证:比分/日期/「某队夺冠过」先核实再作答或纠正;否定性结论(「没打过」)必须先查工具;
- 主观题数字纪律:分析/战术题中任何具体数字必须来自本轮工具结果,查不到只能定性表述;
- 禁止声称「已核实」而实际未调用工具;历史案例枚举宁少勿滥,严禁编「全部 N 次」清单。

本次复查发现模型只查询赛果后，仍可能输出未经查询的球员数字和伤病结论。因此补充了两层实现：

1. 针对已确定具体比赛的统计问题，要求继续调用 `get_game_box`；复盘或关键转折问题还要求查询 `get_game_plays`。失败的查询不会无限重试，交由后续响应说明数据不足。
2. 对识别出的纯单场球员统计意图，直接用 Zod 校验后的工具结果生成得分 / 篮板 / 助攻表格，保留工具进度，替换模型自由发挥的正文。技术统计工具每队保留最多 9 名球员；这不是全名单展示。

赛季统计、比较与开放式分析仍走模型正文，未实现通用的逐句事实核验。基于规则的意图识别也不覆盖所有自然语言表达；已有的单场校验不能被表述为「全面消除幻觉」。

5.2 合规红线(六类,先拒答不检索)

政治地缘/社会争议;场外隐私与绯闻;法律指控与司法细节;黑哨假球等无证据阴谋指控;博彩盘口与涉金钱预测;侮辱性绰号与人身攻击(用侮辱性绰号指代球员时不映射、不给数据)。正常篮球评价与不涉金钱的夺冠预测照常作答。旧版记录中的 I1–I7 及「盘口包装」「造星阴谋包装」「绰号变体」等样本通过；当前版本未重新执行全量红线评测，不据此作零漏过保证。

5.3 旧版评测回路与结果（历史记录）

以下数据沿用 `scripts/eval-results.md` 的旧版记录。题库扩充至 31 问，但没有在当前交付版本全量重跑；不能把历史结果当作当前版本的通过率：

阶段	不合格数	说明
R1 首轮	11/24	提示词 v1:记忆污染大面积发作(编比分/编冠军/生涯赛季混读)
6 轮提示词修补	5/31	工具优先/无年份锚定/season 语义纠正/冠军强制倒查/禁虚假声明/清单纪律
+get_champions 工具	**2/31**	A2/C1/D1 三题转良好(见下);仅剩 F1/F2 观点题伪统计

旧文汇总为优秀 6 / 良好 15 / 合格 5 / 不合格 2，合计 28 项，与 31 问题库数量不一致；未补齐逐题口径前，不报告 31 题完整分布或通过率。记录中的 F1「1–3 翻盘史」与 F2「如何限制 SGA」仍有伪统计；qwen-max 在这两个 A/B 样本上表现更好，不构成根治保证。

工程案例：补充数据工具，改善冠军历史类问题。 C1「雷霆上次夺冠」五轮提示词修补(含逐年倒查规则)均失败——模型的先验「雷霆零冠」压倒工具纪律,甚至编造 2025–26 总决赛赛程,最后一轮 12 步耗尽在逐日查询。根因是**现有工具里根本没有「历年冠军」这个信息**提示词无法凭空注入先验。修复:新增 `get_champions` 工具(中文维基冠军列表,~3.2KB)+ 提示词强制冠军类先调它。一次调用 14.4s 答对(2025 年 4–3 胜步行者),同轮 A2(Siakam G7 数据)与 D1(25 分前提纠偏)的评测等级也改善，但记录仍有未经本轮核实的附加叙述。这条「先验污染 → 提示词到收益边界 → 补充数据工具」的路径,说明了扩大可查询证据范围的作用，不能由少量成功样本推导出该类问题全部可靠。

5.4 当前交付验证（2026-10-10）

验证项	结果与范围
自动化检查	17 个测试文件、77 项单测通过；修改代码独立 lint 通过；源码默认生产构建及 TypeScript 检查通过
页面与交互	桌面 1440px 与 320 / 390 / 768 / 900 / 1024px 布局无横向溢出；今天默认、日期键盘操作、真实赛程、历史会话、手机菜单、时间线展开与追问、设置关闭、失败与空数据状态通过
比赛状态	隔离浏览器使用状态样本验证未开赛、进行中、延期和完赛入口；样本仅用于交互验证，不冒充真实比赛结果
真实模型统计	默认 qwen-plus 查询北京时间 2025-06-23 总决赛 G7，两队表格取自实际查询；亚历山大 29 分 / 5 篮板 / 12 助攻与工具数据一致，生产样本约 5 秒
上线核对	生产版本 `48ce366` 已发布到 `https://nba-chat.vercel.app/`；公开地址浏览器流程及真实模型统计联调通过
未覆盖与基线	未重跑旧版全部 31 问；开放式分析未做完整事实审计。全仓库仍有基线已有的 47 项 `no-explicit-any` lint 错误，不宣称全仓 lint 通过

6. 成本核算

面试官备注明说「合理规划 token 使用 + 高性价比部署本身也是测试」,以下保留旧版评测期的用量样本和预算估算，不代表当前版本新的账单审计。

6.1 用量实测

项	实测值
单问工具循环轮次	约 5–8 轮(评测期 31 题均值约 7 轮)
单轮工具结果体积	1–8KB(压缩后),约 0.5–2K token
单问输入 token(含多轮累积上下文)	约 8–20K
单问输出 token	约 0.8–1.5K

6.2 历史价格假设下的场景估算

按旧版文档的 qwen-plus 价格假设（输入 ¥0.8/百万、输出 ¥2/百万）计算；未核验当前计费档位、优惠和免费额度，实际费用以百炼控制台为准。

场景	计算	成本
单问(均值)	15K 输入 × 0.8/1M + 1.2K 输出 × 2/1M	≈ **¥0.014**(区间 ¥0.005–0.02)
旧版评测期记录	31 题 + 复测 + A/B 约 50+ 次对话	< ¥1
面试期预估	200 问 × ¥0.02 上界	**< ¥5**
Vercel 部署	Hobby 免费档(Serverless,无常驻)	**¥0**
适用边界	仅为少量演示请求的估算	不能推导长期月成本或正式服务成本

6.3 成本控制手段与已知限制

- **压缩层**是第一杠杆:500KB→1–8KB 直接把单轮工具结果压掉两个数量级,未压缩方案单问成本将放大 10 倍以上;
- **限流 12 req/min/IP**(内存令牌桶):设计意图是防站方 key 被刷爆。**实测诚实披露**:Vercel 多实例分布下该内存级实现基本不生效(线上 ~100 次请求未触发一次 429),仅对单实例内的突发有效;彻底方案需引入外部存储(如 Upstash Redis),出于成本与复杂度考量未引入——demo 阶段以 key 用量告警为实际防线;
- 旧版成本比较中 qwen-flash 更便宜；当前单价需按百炼控制台确认。BYOK 的模型用量由用户所选服务承担，站方仍承担应用托管成本;
- 不做内置 web_search 兜底的原因之一也是成本:搜索结果体积不可控,且与百炼 compatible-mode 混用受限。

7. 关键取舍

决策	选择	放弃了什么	依据
key 策略	站方百炼 key 即开即用 + 站方自选 + BYOK 三档	纯 BYOK(参考产品做法)	评测官零摩擦是第一优先级;BYOK 作为兜底保留,三档线上验证 7 例全过
架构	Next.js 全栈单仓,轻后端	纯静态 + 浏览器直连	服务端取数避免浏览器 CORS 限制;系统提示与限流必须在服务端;Vercel 一站部署
默认模型	qwen-plus	qwen-max 默认	A/B 实测(见下):plus 胜数据题,max 胜观点题;数据题占比与权重更高,默认 plus、把切换权交给用户
默认档时延	qwen-plus 10.7s(C1)vs qwen-max 8.2s(C1)	—	三档线上冒烟实测,max 步数更省反而更快
不做三语	仅简体中文	中英西三语(参考产品有)	笔试题只考中文;多语会稀释提示词预算与评测深度
不做 web_search 兜底	长尾问题按事实纪律答「暂无数据」	通用搜索	成本不可控、与 compatible-mode 混用受限、引入不可验证信源;「诚实说没有」优于「搜到什么算什么」
已知限制:大陆访问	vercel.app 域名大陆需代理	—	如实披露;评测官若无代理,可本地 `npm run dev` 或从站方自选档验证模型能力

qwen-plus vs qwen-max A/B(5 题,生产/本地对照):

题	qwen-plus	qwen-max
A2 Siakam G7 数据	良好(37.3s)	不合格×2 复跑(先验拒绝 2025 决赛,误读工具结果)
C1 雷霆夺冠	良好(14.4s)	优秀(7.0s)
D1 25 分纠偏	良好(34.8s)	不合格(锚定 2019 猛龙后放弃)
F1 1–3 翻盘史	不合格(伪统计+虚称已核实)	**良好**(15.1s,案例全真实零编造)
F2 限制 SGA	不合格(整页伪数据)	**良好**(6.9s,全定性零编造)

结论:**各有盲区,没有全对的一方**。max 在已测 F1/F2 样本中未出现伪统计且更省步骤,但其篮球先验同样过时、且不会像 plus 一样用赛程链路兜底自证;plus 在占比更高的数据题上更稳。故默认 plus,设置面板一键切 max——把权衡透明地交给用户,而不是替用户赌一边。

8. 与参考产品的差异化对照

参考产品(nba.footoo.icu,官方给定的方案说明)是重要的对齐基准,差异点:

维度	参考产品	NBA Chat(本方案)
首次使用	需自配 API key(BYOK)	**即开即用**(站方 key),BYOK 仅作兜底
成本披露	方案说明未给数字	完整核算表:历史价格假设下单问 ¥0.005–0.02、200 问预算 <¥5，非当前月成本承诺（§6）
评测深度	—	31 题线上评测 + ESPN ground truth 逐题核对 + 6 轮修补回路全记录
先验污染应对	—	get_champions 数据工具改善已测「历年冠军」问题(§5.3 亮点案例)
模型档位	单档	三档(默认/自选 qwen-*/BYOK)+ A/B 数据支撑选型
岗位契合	—	模型使用阿里云百炼，前后端部署于 Vercel；可据岗位环境替换为阿里云应用托管，当前未完成该迁移
取数位置	浏览器直连	服务端取数（避免浏览器 CORS 限制，仍依赖上游可用性）

不吹没做的:三语、着陆页演示回放等参考产品的全量特性未做(取舍见 §7);开放式分析的伪统计风险仍存在,切换模型不保证消除该风险;大陆直连 vercel.app 需代理。以上均如实列出——把已知边界讲清楚,本身就是「事实可靠」这个产品主张的一部分。

交付物:线上链接 https://nba-chat.vercel.app · 本方案说明 · 仓库源码(README 含本地运行与部署步骤)· 评测全记录 `scripts/eval-results.md`